Technische Hochschule Ingolstadt

(AML)

Klassifikation des Polyzystischen Ovarsyndroms (PCOS)

Machine-Learning-Modelle auf Basis klinischer Patientendaten

Author: **Nillab Masoud**
Matrikelnummer: 00136169
E-mail: *nim2467@thi.de*

Tutor: **Prof. Dr. Sina Huber**
Abteilung: Data Science
E-mail: *sina.huber@thi.de*

12. Juli 2026

Inhaltsverzeichnis

1 Einleitung **4**
1.1 Motivation und Relevanz des Themas sowie kurze Einführung ins Anwendungsproblem . . . 4
1.2 Ziel der Analyse und Erläuterung, warum Machine Learning in diesem Kontext eingesetzt wird . . . 4
1.3 Überblick über den Aufbau der Ausarbeitung . . . 5

2 Hintergrund und Problemstellung **6**
2.1 Beschreibung des Anwendungsproblems und der Daten . . . 6
2.2 Wichtige Anforderungen und Erfolgskriterien (z.B. Metriken) und deren Relevanz . . . 7
2.3 Herausforderungen und mögliche Einschränkungen bei der Modellierung . . . 8

3 Datenanalyse und Vorverarbeitung **9**
3.1 Explorative Datenanalyse (EDA): Visualisierungen, Erkennen von Mustern und Besonderheiten . . . 9
3.2 Datenbereinigung: Umgang mit fehlenden Werten, Duplikaten, Ausreißern und Datenfehlern . . . 10
3.3 Feature Engineering und Transformationen: Umkodierungen, Normalisierungen und eventuelle Feature-Selektionen . . . 10
3.4 Bezug zur Aufgabenstellung: Erklärung, wie die vorbereiteten Daten zur Lösung des Problems beitragen . . . 11

4 Modellauswahl und Implementierung **12**
4.1 Vorstellung der Modellkandidaten und deren theoretische Grundlagen . . . 12
4.2 Begründete Auswahl der finalen Modelle, die sich aus der Datenstruktur und dem Anwendungsproblem ergeben . . . 13
4.3 Implementierung und Parameterwahl: Übersicht über den Prozess und die gewählten Hyperparameter . . . 14

5 Modellbewertung und Optimierung **15**
5.1 Evaluation der Modelle anhand relevanter Metriken . . . 15
5.2 Overfitting/Underfitting-Überprüfung und Optimierung . . . 16
5.3 Hyperparameter-Optimierung: Methoden und Ergebnisse . . . 17

6 Ergebnisse und Interpretation **18**
6.1 Vergleich der Modelle basierend auf den Ergebnissen und kritische Reflexion der Vor- und Nachteile . . . 18
6.2 Visualisierung der wichtigsten Ergebnisse zur Verdeutlichung der Resultate 19
6.3 Schlussfolgerungen aus den Ergebnissen im Kontext des Anwendungsproblems . . . 19

7 Diskussion und Ausblick **20**
7.1 Handlungsempfehlungen und mögliche Anwendungen der Ergebnisse in der Praxis . . . 20
7.2 Einschränkungen der Studie, potenzielle Verbesserungen oder weitere Ansätze 20

8 Fazit **21**
8.1 Zusammenfassung der zentralen Erkenntnisse und kurzer Ausblick auf potenzielle Weiterentwicklungen 21

Hinweis zur Verwendung von KI-Unterstützung

Im Rahmen dieser Seminararbeit wurden die KI-gestützten Sprachmodelle ChatGPT von OpenAI sowie Gemini von Google unterstützend eingesetzt. Die Modelle dienten ausschließlich der Unterstützung bei der Formulierung, sprachlichen Überarbeitung und Strukturierung der Ausarbeitung. Sämtliche von den Sprachmodellen generierten Inhalte wurden sorgfältig geprüft, kritisch bewertet und gegebenenfalls angepasst, sodass sie die eigene Argumentation, den gewünschten wissenschaftlichen Sprachstil sowie ausschließlich nachvollziehbare und überprüfbare Quellen widerspiegeln.

Die inhaltliche Verantwortung sowie die wissenschaftliche Integrität der vorliegenden Arbeit liegen ausschließlich beim Verfasser. Alle durch ChatGPT und Gemini erzeugten Inhalte wurden eigenständig überprüft, überarbeitet und an die Anforderungen wissenschaftlichen Arbeitens angepasst. Die vorliegende Seminararbeit stellt eine eigenständige wissenschaftliche Leistung des Verfassers dar und erfüllt die Grundsätze wissenschaftlicher Redlichkeit, Eigenständigkeit und Nachvollziehbarkeit. Sämtliche inhaltlichen Entscheidungen, Formulierungen und Schlussfolgerungen können bei Bedarf begründet werden. Neben den ausdrücklich genannten KI-Werkzeugen wurden keine weiteren KI-basierten Hilfsmittel verwendet.

1 Einleitung

1.1 Motivation und Relevanz des Themas sowie kurze Einführung ins Anwendungsproblem

Das polyzystische Ovarialsyndrom, seit 2026 offiziell als Polyendocrine Metabolic Ovarian Syndrome (PMOS) bezeichnet, zählt zu den häufigsten endokrinen Erkrankungen bei Frauen im reproduktiven Alter (Teede u. a., 2026). Die bisherige Bezeichnung Polycystic Ovary Syndrome (PCOS) wurde im Rahmen eines internationalen Konsensusprozesses geändert, da sie die Erkrankung nur unzureichend beschreibt. Der frühere Name legte den Fokus stark auf ovarielle Zysten, obwohl diese weder bei allen Betroffenen auftreten noch den gesamten pathophysiologischen Charakter der Erkrankung abbilden. Stattdessen handelt es sich um ein komplexes endokrin-metabolisches Syndrom, das hormonelle, metabolische, reproduktive und psychosoziale Aspekte umfasst (International Evidence-based Guideline for PMOS, 2026). Da der in dieser Arbeit verwendete Datensatz sowie große Teile der bisherigen wissenschaftlichen Literatur weiterhin den Begriff PCOS verwenden, wird im weiteren Verlauf die Bezeichnung PCOS/PMOS genutzt.

PCOS/PMOS ist durch eine hohe klinische Heterogenität gekennzeichnet. Typische Merkmale umfassen Zyklusstörungen, Hyperandrogenismus, Insulinresistenz, Adipositas sowie Veränderungen der Ovarialfunktion. Darüber hinaus kann die Erkrankung mit einem erhöhten Risiko für metabolische Folgeerkrankungen, Infertilität und psychische Belastungen verbunden sein (International Evidence-based Guideline for PMOS, 2026). Aufgrund der unterschiedlichen Ausprägung der Symptome ist eine frühzeitige und eindeutige Diagnosestellung in der Praxis häufig herausfordernd.

Vor diesem Hintergrund gewinnt die datenbasierte Unterstützung medizinischer Entscheidungsprozesse an Bedeutung. Verfahren des Machine Learnings können dabei helfen, Muster in klinischen, hormonellen und metabolischen Merkmalen zu erkennen und zur Klassifikation von Patientinnen beizutragen. Ziel ist dabei nicht, die ärztliche Diagnose zu ersetzen, sondern eine ergänzende, reproduzierbare Entscheidungsunterstützung bereitzustellen.

1.2 Ziel der Analyse und Erläuterung, warum Machine Learning in diesem Kontext eingesetzt wird

Ziel dieser Seminararbeit ist die Entwicklung und Evaluation von Machine-Learning-Modellen zur Klassifikation von Patientinnen hinsichtlich des Vorliegens eines polyzystischen Ovarialsyndroms beziehungsweise Polyendocrine Metabolic Ovarian Syndrome (PCOS/PMOS). Hierfür wird ein öffentlich verfügbarer Datensatz verwendet, der klinische, hormonelle und metabolische Merkmale von Patientinnen umfasst. Auf Grundlage dieser Merkmale soll untersucht werden, inwieweit verschiedene Klassifikationsverfahren in der Lage sind, das Vorliegen von PCOS/PMOS zuverlässig vorherzusagen.

Im Mittelpunkt der Analyse steht der Vergleich mehrerer Machine-Learning-Modelle hinsichtlich ihrer Vorhersageleistung. Die Modelle werden anhand geeigneter Evaluationsmetriken bewertet und miteinander verglichen, um die Stärken und Schwächen der jeweiligen

Verfahren im Anwendungskontext herauszuarbeiten. Darüber hinaus werden die Auswirkungen der Datenvorverarbeitung, der Merkmalsauswahl sowie der Hyperparameteroptimierung auf die Modellgüte untersucht. Ziel ist es nicht ausschließlich, das Modell mit der höchsten Vorhersagegenauigkeit zu identifizieren, sondern die Ergebnisse im Hinblick auf ihre Robustheit, Interpretierbarkeit und praktische Anwendbarkeit kritisch zu bewerten.

Der Einsatz von Machine Learning bietet sich insbesondere deshalb an, weil die Diagnose von PCOS/PMOS auf einer Vielzahl miteinander interagierender klinischer Merkmale basiert. Zwischen hormonellen Parametern, Stoffwechselwerten und weiteren medizinischen Einflussgrößen bestehen häufig komplexe, teilweise nichtlineare Zusammenhänge, die sich mit klassischen regelbasierten Verfahren oder einfachen statistischen Modellen nur eingeschränkt erfassen lassen (James u. a., 2023; Murphy, 2022). Machine-Learning-Verfahren besitzen die Fähigkeit, solche Zusammenhänge aus vorhandenen Daten zu lernen und daraus Vorhersagemodelle abzuleiten, die auch bei neuen Patientinnen angewendet werden können.

Gleichzeitig ist zu betonen, dass Machine-Learning-Modelle die ärztliche Diagnosestellung nicht ersetzen können. Vielmehr stellen sie ein unterstützendes Werkzeug dar, das medizinisches Fachpersonal bei der Entscheidungsfindung ergänzen kann. Insbesondere im Rahmen einer frühen Risikoabschätzung oder als Bestandteil klinischer Entscheidungsunterstützungssysteme können datengetriebene Modelle dazu beitragen, potenziell betroffene Patientinnen frühzeitig zu identifizieren und diagnostische Prozesse effizienter zu gestalten. Voraussetzung hierfür ist jedoch, dass die entwickelten Modelle anhand geeigneter Evaluationsverfahren überprüft werden und ihre Ergebnisse nachvollziehbar sowie medizinisch interpretierbar sind.

1.3 Überblick über den Aufbau der Ausarbeitung

Die vorliegende Seminararbeit gliedert sich in acht inhaltliche Kapitel, die den vollständigen Prozess eines Machine-Learning-Projekts von der Problemdefinition bis zur Interpretation der Ergebnisse systematisch abbilden.

Nach der Einleitung werden in Kapitel 2 die fachlichen Grundlagen sowie das Anwendungsproblem erläutert. Darüber hinaus werden der verwendete Datensatz vorgestellt, zentrale Anforderungen definiert und die für die Bewertung der Modelle relevanten Erfolgskriterien beschrieben. Abschließend werden mögliche Herausforderungen und Einschränkungen der Modellierung diskutiert.

Kapitel 3 befasst sich mit der Datenanalyse und der Datenvorverarbeitung. Neben einer explorativen Datenanalyse werden Maßnahmen zur Datenbereinigung, zum Umgang mit fehlenden Werten und Ausreißern sowie Verfahren des Feature Engineerings und der Datenaufbereitung vorgestellt. Dabei wird erläutert, wie diese Schritte zur Verbesserung der Modellqualität beitragen.

In Kapitel 4 werden geeignete Machine-Learning-Verfahren vorgestellt und hinsichtlich ihrer Eignung für das vorliegende Klassifikationsproblem begründet. Anschließend wird die Implementierung der ausgewählten Modelle sowie die Wahl relevanter Hyperparameter

beschrieben.

Die Bewertung und Optimierung der Modelle erfolgt in Kapitel 5. Hier werden die entwickelten Modelle anhand geeigneter Evaluationsmetriken verglichen sowie Maßnahmen zur Vermeidung von Overfitting beziehungsweise Underfitting und Verfahren der Hyperparameteroptimierung vorgestellt.

Kapitel 6 präsentiert die erzielten Ergebnisse und interpretiert diese im Kontext des Anwendungsproblems. Die Leistungsfähigkeit der Modelle wird kritisch verglichen und anhand geeigneter Visualisierungen veranschaulicht. Darauf aufbauend werden in Kapitel 7 die Ergebnisse diskutiert, Limitationen der Arbeit aufgezeigt sowie mögliche Verbesserungen und zukünftige Forschungsansätze erörtert. Den Abschluss bildet Kapitel 8, in dem die wichtigsten Erkenntnisse der Arbeit zusammengefasst und ein kurzer Ausblick auf potenzielle Weiterentwicklungen gegeben wird.

2 Hintergrund und Problemstellung

2.1 Beschreibung des Anwendungsproblems und der Daten

Das polyzystische Ovarialsyndrom, inzwischen im internationalen Konsensusprozess auch als Polyendocrine Metabolic Ovarian Syndrome (PMOS) bezeichnet, ist eine häufige endokrin-metabolische Erkrankung bei Frauen im reproduktiven Alter. Da der verwendete Datensatz und große Teile der bisherigen Literatur weiterhin die Bezeichnung PCOS nutzen, wird in dieser Arbeit der Begriff PCOS/PMOS verwendet. Die Erkrankung kann sich durch Zyklusstörungen, hormonelle Auffälligkeiten, metabolische Veränderungen sowie sonografische Merkmale der Ovarien äußern. Aufgrund dieser klinischen Heterogenität ist die Diagnose in der Praxis anspruchsvoll und erfordert die gemeinsame Betrachtung mehrerer Merkmale (Teede u. a., 2026).

Das Anwendungsproblem dieser Arbeit besteht darin, anhand klinischer Patientinnendaten vorherzusagen, ob PCOS vorliegt oder nicht. Es handelt sich somit um ein überwachtes binäres Klassifikationsproblem. Die Zielvariable ist im Datensatz als `PCOS (Y/N)` enthalten und wurde für die Analyse in `PCOS_YN` umbenannt, wobei 0 für „kein PCOS“ und 1 für „PCOS“ steht. Ziel ist nicht die Ersetzung ärztlicher Diagnostik, sondern die Untersuchung, ob Machine-Learning-Modelle relevante Muster in den vorhandenen Daten erkennen und eine datenbasierte Entscheidungsunterstützung leisten können.

Der verwendete Datensatz stammt aus der öffentlich zugänglichen Kaggle-Datenquelle *PCOS data* und umfasst 541 Patientinnenbeobachtungen (Bobby, 2021). Die Merkmale beschreiben unter anderem demografische und anthropometrische Informationen wie Alter, Gewicht, Körpergröße und BMI, hormonelle Laborwerte wie FSH, LH, AMH und TSH, metabolische Werte wie RBS sowie klinische Symptome wie Gewichtszunahme, verstärkten Haarwuchs, Hautverdunkelung, Haarausfall, Akne, Fast-Food-Konsum und regelmäßige körperliche Aktivität. Zusätzlich enthält der Datensatz sonografische Merkmale wie die Follikelanzahl und die durchschnittliche Follikelgröße auf linker und rechter Seite sowie die Endometriumdicke.

Für die Modellierung wurden technische oder für die Aufgabenstellung weniger relevante Merkmale entfernt und die Spaltennamen vereinheitlicht. Zudem wurden aus den linken und rechten Follikelmerkmalen zwei neue Features gebildet: `Follicle_no_max` als Maximum der linken und rechten Follikelanzahl sowie `Avg_F_size_max_mm` als Maximum der durchschnittlichen Follikelgröße. Dadurch werden zentrale sonografische Informationen kompakter abgebildet. Insgesamt bietet der Datensatz eine geeignete Grundlage, um verschiedene Klassifikationsmodelle hinsichtlich ihrer Fähigkeit zur PCOS-Erkennung zu vergleichen.

2.2 Wichtige Anforderungen und Erfolgskriterien (z.B. Metriken) und deren Relevanz

Für die Bewertung der Modelle müssen Erfolgskriterien gewählt werden, die zum medizinischen Anwendungskontext und zur Struktur des Datensatzes passen. Da es sich um ein binäres Klassifikationsproblem handelt, wird vorhergesagt, ob eine Patientin der Klasse `PCOS_YN = 1` oder der Klasse `PCOS_YN = 0` zugeordnet wird. Eine reine Betrachtung der Accuracy ist dabei nur eingeschränkt geeignet, da der Datensatz kein vollständig ausgeglichenes Klassenverhältnis aufweist. Ein Modell könnte eine hohe Accuracy erreichen, indem es vor allem die Mehrheitsklasse korrekt erkennt, ohne die PCOS-Fälle ausreichend zuverlässig zu identifizieren.

Daher werden in dieser Arbeit mehrere Metriken gemeinsam betrachtet. Besonders relevant ist der Recall der positiven Klasse, da er angibt, welcher Anteil der tatsächlich betroffenen Patientinnen korrekt als PCOS erkannt wird:

$$Recall = \frac{TP}{TP + FN}.$$

Ein niedriger Recall wäre im medizinischen Kontext problematisch, da viele tatsächlich betroffene Patientinnen übersehen würden. Zusätzlich wird die Precision betrachtet:

$$Precision = \frac{TP}{TP + FP}.$$

Sie gibt an, wie viele der als PCOS klassifizierten Fälle tatsächlich positiv sind. Eine hohe Precision ist wichtig, um unnötige Fehlalarme zu reduzieren. Der F1-Score kombiniert Precision und Recall über das harmonische Mittel und eignet sich daher besonders zur zusammenfassenden Bewertung bei ungleich verteilten Klassen:

$$F1 = 2 \cdot \frac{Precision \cdot Recall}{Precision + Recall}.$$

Neben diesen klassenbezogenen Metriken wird die ROC-AUC verwendet. Sie misst die Trennfähigkeit eines Modells über verschiedene Klassifikationsschwellen hinweg und ist damit hilfreich, um Modelle unabhängig von einem einzelnen Schwellenwert zu vergleichen (James u. a., 2023). Für die Hyperparameter-Optimierung wird ROC-AUC als zentrale Optimierungsmetrik verwendet, da sie die grundsätzliche Fähigkeit des Modells bewertet, PCOS- und Nicht-PCOS-Fälle voneinander zu unterscheiden.

Ein erfolgreiches Modell sollte daher nicht nur eine hohe Gesamtleistung zeigen, sondern insbesondere PCOS-Fälle zuverlässig erkennen, stabile Ergebnisse auf dem Testdatensatz

liefern und interpretierbar genug sein, um die wichtigsten Einflussmerkmale nachvollziehen zu können. Die Bewertung erfolgt deshalb anhand einer Kombination aus ROC-AUC, Precision, Recall, F1-Score und Konfusionsmatrix.

2.3 Herausforderungen und mögliche Einschränkungen bei der Modellierung

Bei der Modellierung des PCOS/PMOS-Datensatzes ergeben sich mehrere Herausforderungen, die bei der Interpretation der Ergebnisse berücksichtigt werden müssen. Eine zentrale Einschränkung ist die begrenzte Größe des Datensatzes. Mit 541 Patientinnenbeobachtungen steht zwar eine nutzbare Datenbasis zur Verfügung, dennoch ist der Umfang für medizinische Machine-Learning-Anwendungen vergleichsweise klein. Dadurch besteht das Risiko, dass Modelle spezifische Muster des vorliegenden Datensatzes lernen, die sich nicht ohne Weiteres auf andere Patientinnengruppen übertragen lassen.

Eine weitere Herausforderung ist das ungleiche Klassenverhältnis zwischen Patientinnen mit und ohne PCOS. Dadurch kann ein Modell dazu tendieren, die häufiger vertretene Klasse bevorzugt vorherzusagen. Aus diesem Grund werden neben der Accuracy insbesondere Recall, Precision, F1-Score und ROC-AUC betrachtet. Gerade im medizinischen Kontext ist es wichtig, dass PCOS-Fälle nicht systematisch übersehen werden.

Zusätzlich enthält der Datensatz verschiedene klinische, hormonelle und sonografische Merkmale, die teilweise miteinander zusammenhängen können. Beispielsweise können BMI, Zyklusmerkmale, AMH-Werte und Follikelanzahl in unterschiedlicher Weise mit dem Krankheitsbild verbunden sein. Solche Korrelationen können die Interpretation einzelner Merkmale erschweren. Zudem handelt es sich um einen beobachtenden Datensatz, sodass aus den Modellvorhersagen keine kausalen Zusammenhänge abgeleitet werden dürfen.

Auch die Datenqualität stellt eine mögliche Einschränkung dar. Öffentlich verfügbare Datensätze können Messfehler, uneinheitliche Erfassungsmethoden oder nicht vollständig dokumentierte Entstehungskontexte enthalten. Deshalb wurden fehlende Werte, Ausreißer, Duplikate und unplausible Merkmale systematisch geprüft. Dennoch kann nicht ausgeschlossen werden, dass bestimmte Verzerrungen im Datensatz verbleiben.

Schließlich ist die medizinische Interpretierbarkeit der Modelle entscheidend. Komplexere Verfahren wie Random Forest oder XGBoost können nichtlineare Zusammenhänge gut abbilden, sind aber weniger transparent als einfache Modelle wie die logistische Regression oder ein einzelner Entscheidungsbaum. Die Ergebnisse werden daher nicht als automatisierte Diagnose verstanden, sondern als datenbasierte Unterstützung zur Analyse relevanter Muster. Die Aussagekraft der Modelle hängt somit nicht nur von ihrer Vorhersageleistung ab, sondern auch von ihrer Robustheit, Nachvollziehbarkeit und Generalisierbarkeit (James u. a., 2023; Murphy, 2022).

3 Datenanalyse und Vorverarbeitung

3.1 Explorative Datenanalyse (EDA): Visualisierungen, Erkennen von Mustern und Besonderheiten

Die explorative Datenanalyse dient dazu, die Struktur des Datensatzes zu verstehen, mögliche Datenprobleme zu erkennen und erste Zusammenhänge zwischen den Merkmalen und der Zielvariable `PCOS_YN` zu untersuchen. Dazu wurden zunächst grundlegende Kennzahlen wie Anzahl der Beobachtungen, Datentypen, fehlende Werte, Verteilungen und deskriptive Statistiken analysiert. Die EDA ist ein zentraler Schritt im Machine-Learning-Prozess, da die Qualität und Struktur der Eingangsdaten direkten Einfluss auf die spätere Modellleistung haben (James u. a., 2023).

Zunächst wurde die Verteilung der Zielvariable betrachtet. Der Datensatz ist nicht vollständig ausgeglichen: Die Klasse `PCOS_YN = 0` tritt häufiger auf als die Klasse `PCOS_YN = 1`. Dieses Klassenungleichgewicht ist für die spätere Modellbewertung relevant, da eine reine Betrachtung der Accuracy zu einer verzerrten Einschätzung führen könnte. Deshalb werden in der Evaluation zusätzlich Recall, Precision, F1-Score und ROC-AUC berücksichtigt.

Zur Untersuchung der numerischen Merkmale wurden Histogramme und Boxplots erstellt. Dabei wurden zentrale klinische und sonografische Variablen wie `BMI`, `Cycle_length_days`, `AMH_ng_mL`, `Follicle_no_max`, `Avg_F_size_max_mm` und `Endometrium_mm` betrachtet. Die Boxplots nach Zielklasse zeigen, ob sich die Verteilungen zwischen Patientinnen mit und ohne PCOS unterscheiden. Besonders sonografische Merkmale wie die maximale Follikelanzahl sind für die Analyse relevant, da sie einen medizinisch plausiblen Bezug zum Krankheitsbild besitzen.

Auffällig war insbesondere, dass die Zielvariable nicht vollständig ausgeglichen verteilt ist und die Nicht-PCOS-Klasse häufiger vorkommt als die PCOS-Klasse. Zudem zeigten die Boxplots deutliche Unterschiede bei sonografischen Merkmalen wie `Follicle_no_max`. Auch einzelne hormonelle Laborwerte wiesen sichtbare Streuungen und potenzielle Ausreißer auf, weshalb eine robuste Ausreißerbehandlung innerhalb der Modell-Pipeline berücksichtigt wurde.

Zusätzlich wurden binäre klinische Symptome wie Gewichtszunahme, verstärkter Haarwuchs, Hautverdunkelung, Haarausfall, Akne, Fast-Food-Konsum und regelmäßige körperliche Aktivität nach Zielklasse untersucht. Dadurch lässt sich erkennen, ob bestimmte Symptome in der PCOS-Gruppe häufiger auftreten. Ergänzend wurde eine Korrelationsanalyse durchgeführt, um lineare Zusammenhänge und mögliche Redundanzen zwischen Merkmalen sichtbar zu machen. Die EDA zeigt somit erste Muster im Datensatz, ersetzt jedoch keine kausale Interpretation. Sie bildet vielmehr die Grundlage für die anschließende Datenbereinigung, Feature-Selektion und Modellierung.

3.2 Datenbereinigung: Umgang mit fehlenden Werten, Duplikaten, Ausreißern und Datenfehlern

Die Datenbereinigung ist ein zentraler Schritt, um eine verlässliche Grundlage für die Modellierung zu schaffen. Zunächst wurden die Spaltennamen vereinheitlicht und technische Importartefakte sowie Identifikationsspalten entfernt. Dazu zählen insbesondere die leere Importspalte `Unnamed_42` sowie laufende Nummern und Patientendateinummern. Solche Variablen enthalten keine medizinisch relevante Information und könnten zu Scheinkorrelationen führen.

Anschließend wurden die Datentypen geprüft und die Variablen numerisch konvertiert. Dabei wurde kontrolliert, ob durch die Konvertierung fehlerhafte oder nichtnumerische Einträge als fehlende Werte entstehen. Fehlende Werte wurden im Modellierungsdatensatz geprüft. Da Machine-Learning-Modelle in der Regel keine fehlenden Werte direkt verarbeiten können, wurde die Vorverarbeitung so aufgebaut, dass fehlende numerische Werte bei Bedarf innerhalb der Pipeline imputiert werden. Dadurch wird verhindert, dass Informationen aus dem Testdatensatz unbeabsichtigt in das Training einfließen.

Zusätzlich wurde der Datensatz auf exakte Duplikate geprüft. Doppelte Beobachtungen können die Modellbewertung verzerren, da identische Fälle im Training und Test indirekt zu einer überschätzten Modellleistung führen können. Exakte Duplikate wurden daher vor der Modellierung entfernt.

Ausreißer wurden mithilfe der 1,5-IQR-Regel identifiziert. Dabei wird der Interquartilsabstand $IQR = Q_3 - Q_1$ verwendet, um Werte außerhalb des Bereichs

$$[Q_1 - 1{,}5 \cdot IQR,\ Q_3 + 1{,}5 \cdot IQR]$$

als potenzielle Ausreißer zu markieren. Diese Werte wurden jedoch nicht pauschal als fehlerhaft gelöscht, da extreme Labor- oder Ultraschallwerte im medizinischen Kontext durchaus relevante Informationen enthalten können. Stattdessen wurden kontinuierliche Merkmale innerhalb der Modell-Pipeline auf aus den Trainingsdaten gelernte IQR-Grenzen begrenzt. Dieses Vorgehen erhöht die Robustheit der Modelle und reduziert gleichzeitig das Risiko von Datenleckage (James u. a., 2023).

3.3 Feature Engineering und Transformationen: Umkodierungen, Normalisierungen und eventuelle Feature-Selektionen

Im Rahmen des Feature Engineerings wurden die Daten so aufbereitet, dass sie für die anschließende Modellierung geeignet sind. Zunächst wurde die Zielvariable `PCOS (Y/N)` in `PCOS_YN` umbenannt. Dabei beschreibt der Wert 0 Patientinnen ohne PCOS und der Wert 1 Patientinnen mit PCOS. Dadurch ist das Anwendungsproblem eindeutig als binäre Klassifikation definiert.

Ein zentraler Schritt war die Bildung zweier neuer Merkmale aus den sonografischen Links-Rechts-Angaben. Aus `Follicle_no_R` und `Follicle_no_L` wurde das Merkmal `Follicle_no_max` gebildet. Analog wurde aus `Avg_F_size_R_mm` und `Avg_F_size_L_mm` das Merkmal `Avg_F_size_max_mm` erzeugt. Damit wird jeweils der stärker ausgeprägte

Wert berücksichtigt. Die ursprünglichen Links- und Rechtsmerkmale wurden anschließend entfernt, um redundante Informationen zu reduzieren. Kritisch ist jedoch zu beachten, dass durch diese Maximumsbildung mögliche Asymmetrien zwischen linker und rechter Seite verloren gehen.

Zusätzlich erfolgte eine a-priori Feature-Selektion auf Basis der Aufgabenstellung. Merkmale wie Blutgruppe, Puls, Atemfrequenz, Hämoglobinwert, Ehestatus, Schwangerschaftsstatus, Anzahl der Aborte, Prolaktin, Vitamin D3 sowie systolischer und diastolischer Blutdruck wurden aus der Modellierung ausgeschlossen. Diese Auswahl wird nicht als Nachweis verstanden, dass die Merkmale medizinisch irrelevant sind, sondern als vorab festgelegte Eingrenzung des Modellierungsraums.

Für die Modellierung wurden numerische und diskrete Merkmale innerhalb einer Pipeline unterschiedlich verarbeitet. Fehlende numerische Werte werden mit dem Median imputiert, anschließend werden Ausreißer mithilfe einer IQR-basierten Begrenzung behandelt. Für die logistische Regression werden kontinuierliche Merkmale zusätzlich standardisiert, da dieses Modell empfindlich auf unterschiedliche Skalierungen reagieren kann. Baumbasierte Modelle wie Decision Tree, Random Forest und XGBoost benötigen dagegen keine Standardisierung, da sie auf Schwellenwerten in einzelnen Merkmalen basieren. Diskrete Merkmale werden mit dem häufigsten Wert imputiert und bei Bedarf per One-Hot-Encoding kodiert. Durch die Einbettung dieser Schritte in eine Pipeline wird sichergestellt, dass die Transformationen ausschließlich auf den Trainingsdaten gelernt und anschließend auf Validierungs- und Testdaten angewendet werden. Dadurch wird Datenleckage vermieden (James u. a., 2023).

3.4 Bezug zur Aufgabenstellung: Erklärung, wie die vorbereiteten Daten zur Lösung des Problems beitragen

Die durchgeführten Vorverarbeitungsschritte tragen dazu bei, den PCOS/PMOS-Datensatz in eine konsistente und modellierbare Form zu überführen. Durch die Vereinheitlichung der Spaltennamen, die Entfernung technischer oder nicht relevanter Merkmale sowie die Prüfung auf fehlende Werte, Duplikate und Ausreißer wird die Datenqualität verbessert. Dadurch sinkt das Risiko, dass die Modelle zufällige Artefakte oder fehlerhafte Informationen lernen.

Das Feature Engineering unterstützt die medizinische und technische Zielsetzung der Arbeit. Insbesondere die Bildung von `Follicle_no_max` und `Avg_F_size_max_mm` fasst zentrale sonografische Informationen kompakt zusammen und reduziert Redundanz zwischen linken und rechten Messwerten. Gleichzeitig bleiben klinisch relevante Informationen erhalten, die für die Unterscheidung zwischen Patientinnen mit und ohne PCOS bedeutsam sein können.

Die Transformationen innerhalb der Pipeline stellen sicher, dass alle Modelle mit geeigneten Eingangsdaten trainiert werden. Die Imputation fehlender Werte, die IQR-basierte Begrenzung von Ausreißern und die Standardisierung kontinuierlicher Merkmale bei der logistischen Regression verbessern die Stabilität der Modellierung. Da diese Schritte innerhalb der Pipeline erfolgen, werden sie ausschließlich auf Basis der Trainingsdaten gelernt

und anschließend auf Validierungs- und Testdaten angewendet. Dadurch wird Datenleckage vermieden und die spätere Modellbewertung bleibt aussagekräftig (James u. a., 2023).

Insgesamt schaffen die vorbereiteten Daten die Grundlage dafür, verschiedene Klassifikationsmodelle fair miteinander zu vergleichen. Sie ermöglichen es, zu untersuchen, welche Verfahren PCOS-Fälle zuverlässig erkennen, welche Merkmale für die Vorhersage besonders wichtig sind und wie gut die Modelle auf bisher ungesehenen Testdaten generalisieren.

4 Modellauswahl und Implementierung

4.1 Vorstellung der Modellkandidaten und deren theoretische Grundlagen

Für die Klassifikation von PCOS/PMOS wurden vier überwachte Machine-Learning-Verfahren betrachtet: logistische Regression, Entscheidungsbaum, Random Forest und XGBoost. Da die Zielvariable `PCOS_YN` binär kodiert ist, handelt es sich um ein binäres Klassifikationsproblem. Die ausgewählten Modelle unterscheiden sich hinsichtlich Interpretierbarkeit, Komplexität und Fähigkeit zur Modellierung nichtlinearer Zusammenhänge.
Logistische Regression: Die logistische Regression ist ein lineares Klassifikationsmodell, das die Wahrscheinlichkeit für das Auftreten der positiven Klasse modelliert. Für einen Merkmalsvektor $x = (x_1, x_2, \ldots, x_p)$ wird zunächst eine lineare Kombination der Eingangsvariablen gebildet:

$$z = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \cdots + \beta_p x_p.$$

Diese wird mithilfe der Sigmoid-Funktion in eine Wahrscheinlichkeit transformiert:

$$P(y = 1|x) = \frac{1}{1 + e^{-z}}.$$

Im Kontext dieser Arbeit beschreibt $y = 1$ das Vorliegen von PCOS. Die Koeffizienten β_j geben an, wie stark ein Merkmal die geschätzte Wahrscheinlichkeit der positiven Klasse beeinflusst. Die logistische Regression dient daher als gut interpretierbares Basismodell. Da sie empfindlich gegenüber unterschiedlichen Skalierungen der Merkmale ist, wurden kontinuierliche Variablen vor dem Training standardisiert (James u. a., 2023).
Entscheidungsbaum: Ein Entscheidungsbaum teilt den Merkmalsraum schrittweise anhand von Entscheidungsregeln auf. Jeder innere Knoten enthält eine Bedingung auf ein Merkmal, während die Blätter eine Klassenzuordnung liefern. Für die Auswahl geeigneter Splits werden Unreinheitsmaße verwendet. Typische Kriterien sind die Gini-Unreinheit

$$G = \sum_{k=1}^{K} p_k(1 - p_k)$$

und die Entropie

$$H = -\sum_{k=1}^{K} p_k \log(p_k),$$

wobei p_k den Anteil der Klasse k in einem Knoten beschreibt. Ein Split ist dann vorteilhaft, wenn er die Klassen möglichst gut trennt. Entscheidungsbäume sind gut interpretierbar, können jedoch bei zu großer Tiefe zu Overfitting neigen. Daher wurden Parameter wie `max_depth` und `min_samples_leaf` optimiert (James u. a., 2023).

Random Forest: Random Forest ist ein Ensemble-Verfahren, das viele Entscheidungsbäume kombiniert. Jeder Baum wird auf einer zufälligen Stichprobe der Trainingsdaten trainiert, zusätzlich wird bei jedem Split nur eine zufällige Auswahl der Merkmale betrachtet. Die finale Klassifikation ergibt sich durch Mehrheitsentscheidung der einzelnen Bäume:

$$\hat{y} = \text{mode}\{h_1(x), h_2(x), \ldots, h_B(x)\},$$

wobei $h_b(x)$ die Vorhersage des b-ten Baums und B die Anzahl der Bäume beschreibt. Durch die Kombination vieler Bäume wird die Varianz reduziert, wodurch Random Forest robuster gegenüber Overfitting ist als ein einzelner Entscheidungsbaum. Für den PCOS-Datensatz ist dieses Modell besonders relevant, da es nichtlineare Zusammenhänge und Interaktionen zwischen klinischen, hormonellen und sonografischen Merkmalen abbilden kann (James u. a., 2023).
XGBoost: XGBoost steht für Extreme Gradient Boosting und basiert ebenfalls auf Entscheidungsbäumen. Im Gegensatz zum Random Forest werden die Bäume jedoch sequenziell trainiert. Jeder neue Baum versucht, die Fehler der vorherigen Modelliteration zu korrigieren. Die Zielfunktion besteht aus einer Verlustfunktion und einem Regularisierungsterm:

$$Obj = \sum_{i=1}^{n} L(y_i, \hat{y}_i) + \sum_{k=1}^{T} \Omega(f_k).$$

Dabei beschreibt $L(y_i, \hat{y}_i)$ den Vorhersagefehler und $\Omega(f_k)$ bestraft die Komplexität des jeweiligen Baums. Diese Regularisierung hilft, Overfitting zu begrenzen. Für diese Arbeit wurde XGBoost mit dem Ziel `binary:logistic` eingesetzt, sodass das Modell Wahrscheinlichkeiten für die Klasse PCOS berechnet. XGBoost eignet sich besonders für komplexe tabellarische Datensätze, ist jedoch weniger direkt interpretierbar als eine logistische Regression oder ein einzelner Entscheidungsbaum (Murphy, 2022; XGBoost Developers, 2026).

4.2 Begründete Auswahl der finalen Modelle, die sich aus der Datenstruktur und dem Anwendungsproblem ergeben

Die Auswahl der finalen Modellkandidaten orientiert sich an der Struktur des Datensatzes und an der medizinischen Fragestellung. Da die Zielvariable `PCOS_YN` binär kodiert ist, eignen sich überwachte Klassifikationsverfahren. Zudem handelt es sich um tabellarische klinische Daten mit numerischen Laborwerten, sonografischen Messgrößen und binären Symptommerkmalen. Für diese Datenstruktur wurden logistische Regression, Entscheidungsbaum, Random Forest und XGBoost ausgewählt.

Die logistische Regression wird als interpretierbares Basismodell eingesetzt. Sie ermöglicht es, den Einfluss einzelner Merkmale über Koeffizienten nachzuvollziehen und dient

damit als Referenzmodell für komplexere Verfahren. Dies ist im medizinischen Kontext relevant, da nicht nur die Vorhersageleistung, sondern auch die Nachvollziehbarkeit der Modellentscheidung eine Rolle spielt (James u. a., 2023).

Der Entscheidungsbaum wurde ausgewählt, weil er nichtlineare Entscheidungsregeln abbilden kann und gleichzeitig gut interpretierbar bleibt. Die Entscheidungsstruktur lässt sich visuell darstellen und ermöglicht eine verständliche Analyse, welche Merkmale für die Klassifikation genutzt werden. Gleichzeitig ist bekannt, dass einzelne Entscheidungsbäume anfällig für Overfitting sein können, weshalb eine Begrenzung der Baumtiefe und weiterer Hyperparameter notwendig ist.

Random Forest erweitert dieses Prinzip, indem viele Entscheidungsbäume kombiniert werden. Dadurch wird die Stabilität der Vorhersagen verbessert und die Varianz einzelner Bäume reduziert. Für den PCOS-Datensatz ist dieses Modell besonders geeignet, da medizinische Merkmale häufig nichtlineare Zusammenhänge und Wechselwirkungen aufweisen. Zusätzlich liefert Random Forest Feature Importances, die zur Interpretation der wichtigsten Einflussgrößen genutzt werden können.

XGBoost wurde als weiteres leistungsfähiges Ensemble-Verfahren gewählt. Im Gegensatz zum Random Forest werden die Bäume sequenziell trainiert, wobei jeder neue Baum versucht, die Fehler der vorherigen Modelliteration zu reduzieren. Durch Regularisierung und flexible Hyperparameter eignet sich XGBoost besonders für strukturierte tabellarische Daten und kann komplexe Muster erfassen (XGBoost Developers, 2026). Gleichzeitig ist das Modell weniger direkt interpretierbar und rechenintensiver als einfachere Verfahren.

Die Kombination dieser vier Modelle erlaubt einen ausgewogenen Vergleich zwischen Interpretierbarkeit und Vorhersageleistung. Während logistische Regression und Entscheidungsbaum vor allem als transparente Referenzmodelle dienen, prüfen Random Forest und XGBoost, ob komplexere nichtlineare Verfahren die PCOS-Klassifikation verbessern können.

4.3 Implementierung und Parameterwahl: Übersicht über den Prozess und die gewählten Hyperparameter

Die Implementierung der Modelle erfolgte in Python mithilfe von `scikit-learn` und `xgboost`. Um eine vergleichbare und reproduzierbare Modellierung sicherzustellen, wurden alle Vorverarbeitungsschritte und Modelle in Pipelines eingebettet. Dadurch werden Imputation, Ausreißerbehandlung, Skalierung und Modelltraining gemeinsam ausgeführt. Dies reduziert das Risiko von Datenleckage, da die Transformationen ausschließlich auf den Trainingsdaten gelernt und anschließend auf Validierungs- und Testdaten angewendet werden.

Der Datensatz wurde zunächst in Trainings- und Testdaten aufgeteilt. Die Hyperparameter-Optimierung erfolgte ausschließlich auf den Trainingsdaten mithilfe einer Kreuzvalidierung. Als Optimierungsmetrik wurde die ROC-AUC verwendet, da sie die Trennfähigkeit der Modelle über verschiedene Schwellenwerte hinweg bewertet und somit für das binäre Klassifikationsproblem geeignet ist (James u. a., 2023).

Für die logistische Regression wurden die Regularisierungsstärke `C` mit den Werten 0,1, 1,0 und 10,0 sowie die Regularisierungsart `l1` und `l2` getestet. Als Solver wurde `liblinear` verwendet, da dieser beide Regularisierungsarten unterstützt. Beim Entscheidungsbaum wurden das Split-Kriterium `gini` beziehungsweise `entropy`, die maximale Baumtiefe sowie die minimale Anzahl von Beobachtungen pro Blatt optimiert. Diese Parameter sind besonders relevant, um Overfitting zu begrenzen.

Für Random Forest wurde eine Randomized Search eingesetzt, da der Parameterraum größer ist. Optimiert wurden unter anderem die Anzahl der Bäume, die maximale Baumtiefe, die minimale Blattgröße und die Anzahl der betrachteten Merkmale pro Split. Für XGBoost wurden ebenfalls zufällige Parameterkombinationen getestet, darunter die Anzahl der Bäume, die maximale Tiefe, die Lernrate, Subsampling-Parameter, `min_child_weight` und `reg_lambda`. Diese Parameter steuern sowohl die Modellkomplexität als auch die Regularisierung und sind daher zentral für die Kontrolle von Overfitting (XGBoost Developers, 2026).

Die jeweils besten Modelle aus der Hyperparameter-Optimierung wurden anschließend auf dem unabhängigen Testdatensatz evaluiert. Dadurch wird geprüft, ob die Modelle nicht nur auf den Trainings- und Validierungsdaten gute Ergebnisse erzielen, sondern auch auf bisher ungesehenen Daten generalisieren.

5 Modellbewertung und Optimierung

5.1 Evaluation der Modelle anhand relevanter Metriken

Die Bewertung der Modelle erfolgt anhand mehrerer Klassifikationsmetriken, da eine einzelne Kennzahl die Modellleistung im medizinischen Kontext nicht ausreichend beschreibt. Grundlage der Bewertung ist die Konfusionsmatrix mit den vier Größen True Positives (TP), True Negatives (TN), False Positives (FP) und False Negatives (FN). Besonders kritisch sind im vorliegenden Anwendungsfall falsch negative Vorhersagen, da tatsächlich betroffene Patientinnen fälschlicherweise als unauffällig klassifiziert würden.

Die Accuracy beschreibt den Anteil aller korrekt klassifizierten Fälle:

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN}.$$

Da der Datensatz jedoch kein vollständig ausgeglichenes Klassenverhältnis aufweist, wird die Accuracy nicht als alleinige Hauptmetrik verwendet. Stattdessen ist insbesondere der Recall der positiven Klasse relevant. Er gibt an, welcher Anteil der tatsächlich an PCOS erkrankten Patientinnen korrekt erkannt wird:

$$Recall = \frac{TP}{TP + FN}.$$

Zusätzlich wird die Precision betrachtet. Sie beschreibt, wie viele der als PCOS klassifizierten Fälle tatsächlich positiv sind:

$$Precision = \frac{TP}{TP + FP}.$$

Der F1-Score kombiniert Precision und Recall über das harmonische Mittel und eignet sich daher als zusammenfassende Metrik, wenn beide Fehlerarten berücksichtigt werden sollen:

$$F1 = 2 \cdot \frac{Precision \cdot Recall}{Precision + Recall}.$$

Ergänzend wird die Spezifität berechnet, die den Anteil korrekt erkannter Nicht-PCOS-Fälle beschreibt:

$$Specificity = \frac{TN}{TN + FP}.$$

Neben diesen schwellenwertabhängigen Metriken wird die ROC-AUC verwendet. Sie bewertet die Fähigkeit eines Modells, positive und negative Fälle über verschiedene Klassifikationsschwellen hinweg zu trennen (James u. a., 2023). Eine ROC-AUC von 0,5 entspricht zufälligem Raten, während Werte nahe 1 auf eine hohe Trennfähigkeit hinweisen. Zusätzlich wird die Precision-Recall-AUC betrachtet, da sie insbesondere bei ungleich verteilten Klassen informativ ist. Zur Beurteilung der Wahrscheinlichkeitsqualität wird außerdem der Brier-Score verwendet:

$$Brier = \frac{1}{n} \sum_{i=1}^{n} (\hat{p}_i - y_i)^2.$$

Dabei beschreibt $\hat{p}_i$ die vorhergesagte Wahrscheinlichkeit und y_i die tatsächliche Klasse. Insgesamt erfolgt die Evaluation somit nicht nur anhand der reinen Trefferquote, sondern anhand einer Kombination aus Diskriminierungsfähigkeit, Fehlerarten und Kalibrierung. Dadurch kann beurteilt werden, welches Modell für die PCOS-Klassifikation nicht nur leistungsfähig, sondern auch im Anwendungskontext sinnvoll interpretierbar ist.

5.2 Overfitting/Underfitting-Überprüfung und Optimierung

Overfitting und Underfitting sind zentrale Risiken bei der Entwicklung von Machine-Learning-Modellen. Overfitting liegt vor, wenn ein Modell die Trainingsdaten sehr gut abbildet, aber auf neuen Daten deutlich schlechter generalisiert. Underfitting beschreibt dagegen den Fall, dass ein Modell zu einfach ist und weder auf den Trainings- noch auf den Testdaten ausreichend gute Ergebnisse erzielt (James u. a., 2023).

Zur Überprüfung wurde die Modellleistung auf Trainingsdaten, Kreuzvalidierungsdaten und Testdaten miteinander verglichen. Besonders relevant ist dabei die Differenz zwischen der ROC-AUC auf den Trainingsdaten und der ROC-AUC in der Kreuzvalidierung. Eine große Abweichung würde darauf hindeuten, dass das Modell zu stark an die Trainingsdaten angepasst ist. Zusätzlich wurde die Leistung auf dem unabhängigen Testdatensatz betrachtet, um die Generalisierungsfähigkeit der Modelle zu beurteilen.

Zur Reduktion von Overfitting wurden mehrere Maßnahmen eingesetzt. Bei der logistischen Regression wurde Regularisierung verwendet, wobei unterschiedliche Werte für die Regularisierungsstärke getestet wurden. Beim Entscheidungsbaum wurden die maximale Baumtiefe und die minimale Anzahl von Beobachtungen pro Blatt begrenzt. Für Random Forest und XGBoost wurden ebenfalls komplexitätssteuernde Hyperparameter optimiert,

darunter die Baumtiefe, die Anzahl der Bäume, die minimale Blattgröße beziehungsweise Regularisierungsparameter.

Die Hyperparameter-Optimierung erfolgte ausschließlich auf den Trainingsdaten innerhalb der Kreuzvalidierung. Dadurch wird vermieden, dass Informationen aus dem Testdatensatz in die Modellauswahl einfließen. Die Pipeline-basierte Vorverarbeitung unterstützt dieses Vorgehen zusätzlich, da Imputation, Skalierung und Ausreißerbehandlung nur aus den jeweiligen Trainingsfolds gelernt werden. Insgesamt dient die Overfitting-/Underfitting-Prüfung somit dazu, nicht nur ein leistungsstarkes, sondern auch ein möglichst robustes und generalisierbares Modell für die PCOS-Klassifikation auszuwählen.

5.3 Hyperparameter-Optimierung: Methoden und Ergebnisse

Zur Verbesserung der Modellleistung wurden die Hyperparameter der vier Modellkandidaten systematisch optimiert. Die Optimierung erfolgte ausschließlich auf den Trainingsdaten mithilfe einer 5-fachen stratifizierten Kreuzvalidierung. Dadurch bleibt der Testdatensatz unangetastet und kann anschließend zur unabhängigen Bewertung der Generalisierungsfähigkeit verwendet werden. Als Optimierungsmetrik wurde die ROC-AUC gewählt, da sie die Trennfähigkeit der Modelle unabhängig von einem festen Klassifikationsschwellenwert bewertet (James u. a., 2023).

Für die logistische Regression und den Entscheidungsbaum wurde eine Grid Search verwendet. Dabei werden alle vorher definierten Parameterkombinationen vollständig getestet. Bei der logistischen Regression wurden insbesondere die Regularisierungsstärke `C` sowie die Regularisierungsart `l1` und `l2` untersucht. Beim Entscheidungsbaum wurden das Split-Kriterium, die maximale Baumtiefe und die minimale Anzahl an Beobachtungen pro Blatt optimiert, um eine zu starke Anpassung an die Trainingsdaten zu vermeiden.

Für Random Forest und XGBoost wurde eine Randomized Search eingesetzt, da diese Modelle größere Parameterräume besitzen und eine vollständige Grid Search deutlich rechenintensiver wäre. Beim Random Forest wurden unter anderem die Anzahl der Bäume, die maximale Baumtiefe, die minimale Blattgröße und die Anzahl der pro Split betrachteten Merkmale variiert. Bei XGBoost wurden Parameter wie Anzahl der Bäume, Baumtiefe, Lernrate, Subsampling, `min_child_weight` und `reg_lambda` optimiert. Diese Parameter steuern die Komplexität des Modells und wirken einer Überanpassung entgegen (XGBoost Developers, 2026).

Die Ergebnisse der Hyperparameter-Optimierung zeigen, dass die komplexeren Ensemble-Modelle insgesamt die stärkste Trennfähigkeit erreichen. Insbesondere der Random Forest erzielte in der Kreuzvalidierung die beste ROC-AUC und wurde daher als finales bestes Modell ausgewählt. Gleichzeitig wurde geprüft, ob die Leistung auf Trainings-, Validierungs- und Testdaten konsistent bleibt. Dadurch wird vermieden, ein Modell nur aufgrund einer zufällig guten Validierungsleistung auszuwählen. Die detaillierten Kennzahlen der optimierten Modelle werden im folgenden Ergebnisteil miteinander verglichen und im Hinblick auf Recall, Precision, F1-Score und ROC-AUC interpretiert.

6 Ergebnisse und Interpretation

6.1 Vergleich der Modelle basierend auf den Ergebnissen und kritische Reflexion der Vor- und Nachteile

Die vier Modelle zeigen insgesamt eine gute Trennfähigkeit zwischen Patientinnen mit und ohne PCOS. Die beste Leistung in der Kreuzvalidierung erzielt der Random Forest mit einer CV-ROC-AUC von 0,9595. Auch auf dem unabhängigen Testdatensatz bleibt die Leistung mit einer Test-ROC-AUC von 0,9547 stabil. Zusätzlich erreicht das Modell die höchste Precision von 0,9667 und eine hohe Spezifität von 0,9863. Das bedeutet, dass nur wenige Nicht-PCOS-Fälle fälschlicherweise als PCOS klassifiziert werden. Der Recall liegt jedoch bei 0,8056 und ist damit niedriger als bei den übrigen drei Modellen. Für einen medizinischen Screening-Kontext ist dies kritisch zu betrachten, da falsch negative Fälle möglichst vermieden werden sollten.

XGBoost erreicht mit einer CV-ROC-AUC von 0,9518 und einer Test-ROC-AUC von 0,9486 ebenfalls sehr gute Ergebnisse. Im Vergleich zum Random Forest ist der Recall mit 0,8611 höher, während die Precision mit 0,8857 niedriger ausfällt. XGBoost erkennt somit mehr tatsächliche PCOS-Fälle, produziert aber gleichzeitig mehr falsch positive Vorhersagen. Zusätzlich weist XGBoost mit einem Brier-Score von 0,0729 die beste Kalibrierung der vorhergesagten Wahrscheinlichkeiten auf. Ein Nachteil ist jedoch die geringere direkte Interpretierbarkeit und der höhere Aufwand bei der Hyperparameter-Optimierung (XGBoost Developers, 2026).

Die logistische Regression erreicht eine CV-ROC-AUC von 0,9497 und eine Test-ROC-AUC von 0,9326. Sie liefert damit eine solide Leistung und hat den Vorteil einer hohen Interpretierbarkeit. Ihre Koeffizienten ermöglichen eine nachvollziehbare Einschätzung, welche Merkmale die Wahrscheinlichkeit für die positive Klasse erhöhen oder senken. Gleichzeitig ist die Precision mit 0,7750 deutlich niedriger als bei Random Forest und XGBoost. Das Modell klassifiziert daher vergleichsweise mehr Nicht-PCOS-Fälle fälschlicherweise als PCOS. Dies zeigt, dass die lineare Modellannahme für die komplexen Zusammenhänge im Datensatz nur eingeschränkt ausreicht (James u. a., 2023).

Der Entscheidungsbaum erzielt mit einer CV-ROC-AUC von 0,8973 die schwächste Validierungsleistung der vier Modelle. Auf dem Testdatensatz erreicht er zwar eine Test-ROC-AUC von 0,9422 und einen Recall von 0,8611, jedoch bleiben Precision und F1-Score niedriger als bei den Ensemble-Modellen. Sein größter Vorteil liegt in der einfachen Interpretierbarkeit, da Entscheidungsregeln visuell nachvollzogen werden können. Gleichzeitig ist ein einzelner Entscheidungsbaum anfälliger für instabile Entscheidungen und Overfitting, insbesondere bei kleineren medizinischen Datensätzen.

Zusammenfassend zeigt der Random Forest die ausgewogenste Gesamtleistung und wird deshalb als finales Modell ausgewählt. Er kombiniert die höchste CV-ROC-AUC, eine stabile Testleistung, hohe Precision und sehr hohe Spezifität. XGBoost stellt eine starke Alternative dar, insbesondere wenn der Fokus stärker auf Recall und Wahrscheinlichkeitskalibrierung liegt. Die logistische Regression bleibt als transparente Baseline wertvoll, während der Entscheidungsbaum vor allem zur Veranschaulichung einzelner Entscheidungs-

regeln geeignet ist. Die finale Modellauswahl basiert daher nicht nur auf einer einzelnen Metrik, sondern auf dem Zusammenspiel von Trennfähigkeit, Fehlerarten, Stabilität und Interpretierbarkeit.

6.2 Visualisierung der wichtigsten Ergebnisse zur Verdeutlichung der Resultate

Zur anschaulichen Darstellung der Modellleistung wurden mehrere Visualisierungen eingesetzt. Die ROC-Kurven zeigen, wie gut die einzelnen Modelle zwischen PCOS- und Nicht-PCOS-Fällen unterscheiden können. Die gestrichelte Diagonale dient dabei als Referenz für einen Zufallsklassifikator. Alle betrachteten Modelle liegen deutlich oberhalb dieser Linie, was auf eine grundsätzlich gute Trennfähigkeit hinweist. Besonders Random Forest und XGBoost zeigen eine hohe ROC-AUC und damit eine starke Diskriminierungsleistung.

Ergänzend wurden Konfusionsmatrizen bei einem Klassifikationsschwellenwert von 0,5 erstellt. Diese zeigen, wie viele Fälle korrekt oder falsch als PCOS beziehungsweise Nicht-PCOS klassifiziert wurden. Dadurch lassen sich insbesondere False Positives und False Negatives sichtbar machen. Im medizinischen Kontext sind False Negatives besonders kritisch, da tatsächlich betroffene Patientinnen übersehen würden. Die Konfusionsmatrizen ermöglichen somit eine differenziertere Bewertung als eine reine Gesamtkennzahl.

Zusätzlich wurden Feature-Importance-Plots für die baumbasierten Modelle betrachtet. Diese zeigen, welche Merkmale besonders stark zur Modellentscheidung beitragen. Dabei fällt insbesondere `Follicle_no_max` als wichtiges Merkmal auf. Dies ist fachlich plausibel, da die Follikelanzahl im Zusammenhang mit PCOS/PMOS eine diagnostisch relevante Rolle spielen kann. Dennoch dürfen Feature Importances nicht kausal interpretiert werden. Sie zeigen lediglich, welche Variablen das Modell für seine Vorhersagen stark nutzt, nicht aber, ob diese Merkmale eine Ursache der Erkrankung darstellen.

Insgesamt helfen die Visualisierungen dabei, die numerischen Ergebnisse verständlicher einzuordnen. Während die ROC-Kurven die allgemeine Trennfähigkeit der Modelle verdeutlichen, zeigen die Konfusionsmatrizen konkrete Fehlklassifikationen. Die Feature-Importance-Analysen liefern zusätzlich Hinweise darauf, welche klinischen oder sonografischen Merkmale für die Modellentscheidungen besonders bedeutsam waren.

6.3 Schlussfolgerungen aus den Ergebnissen im Kontext des Anwendungsproblems

Die Ergebnisse zeigen, dass die untersuchten Modelle relevante Muster in den klinischen, hormonellen und sonografischen Merkmalen des PCOS/PMOS-Datensatzes erkennen können. Besonders die hohe ROC-AUC der Ensemble-Modelle deutet darauf hin, dass eine datenbasierte Unterscheidung zwischen Patientinnen mit und ohne PCOS grundsätzlich möglich ist.

Für den vorliegenden Datensatz erweist sich der Random Forest als stärkstes Gesamtmodell. Seine hohe Precision und Spezifität zeigen, dass nur wenige Nicht-PCOS-Fälle

fälschlicherweise als PCOS klassifiziert werden. Gleichzeitig bleibt der Recall kritisch zu betrachten, da falsch negative Vorhersagen im medizinischen Kontext besonders problematisch sein können. Für einen Screening-orientierten Einsatz wäre daher eine Schwellenwertanpassung zu prüfen.

Die Feature-Importance-Analyse unterstreicht die Bedeutung sonografischer Merkmale, insbesondere der maximalen Follikelanzahl. Dies ist fachlich plausibel, darf jedoch nicht kausal interpretiert werden. Insgesamt zeigen die Ergebnisse den methodischen Nutzen von Machine Learning zur Analyse von PCOS/PMOS-Daten, ohne daraus eine eigenständige diagnostische Anwendbarkeit abzuleiten.

7 Diskussion und Ausblick

7.1 Handlungsempfehlungen und mögliche Anwendungen der Ergebnisse in der Praxis

Auf Grundlage der Ergebnisse könnte ein Machine-Learning-Modell perspektivisch als ergänzendes Werkzeug zur strukturierten Risikoabschätzung eingesetzt werden. Eine mögliche Anwendung wäre ein Screening-ähnlicher Einsatz, bei dem Patientinnen mit auffälligem Risikoprofil für eine weiterführende ärztliche Abklärung priorisiert werden. Dabei wäre das Modell nicht als Diagnoseinstrument zu verstehen, sondern als unterstützende Komponente innerhalb eines ärztlich kontrollierten Entscheidungsprozesses.

Für einen solchen Einsatz müsste der Klassifikationsschwellenwert an den konkreten Anwendungskontext angepasst werden. Soll das Modell möglichst viele potenziell betroffene Patientinnen erkennen, müsste der Recall priorisiert werden. Dies würde jedoch voraussichtlich zu mehr falsch positiven Vorhersagen führen. Die Wahl des Schwellenwerts wäre daher keine rein technische Entscheidung, sondern müsste medizinisch und organisatorisch begründet werden.

Die Feature-Importance-Analyse kann zudem Hinweise darauf geben, welche Merkmale bei zukünftigen Datenerhebungen besonders sorgfältig dokumentiert werden sollten. Insbesondere sonografische Merkmale wie `Follicle_no_max` erscheinen im vorliegenden Datensatz relevant für die Klassifikation. Vor einer praktischen Nutzung wären jedoch externe Validierung, transparente Fehleranalyse, medizinische Plausibilitätsprüfung und eine klare Mensch-Modell-Verantwortung erforderlich.

7.2 Einschränkungen der Studie, potenzielle Verbesserungen oder weitere Ansätze

Die Aussagekraft der Ergebnisse ist durch mehrere Faktoren begrenzt. Eine zentrale Einschränkung ist die vergleichsweise kleine Datenbasis mit 541 Patientinnenbeobachtungen. Obwohl der Datensatz für eine explorative Machine-Learning-Analyse geeignet ist, reicht er nicht aus, um eine allgemein gültige Aussage über die diagnostische Nutzbarkeit der Modelle zu treffen. Insbesondere bei medizinischen Anwendungen ist eine Validierung an unabhängigen externen Datensätzen notwendig, um die Generalisierbarkeit zu überprüfen.

Eine weitere Einschränkung ergibt sich aus der Herkunft des Datensatzes. Da es sich um einen öffentlich verfügbaren Kaggle-Datensatz handelt, sind Erhebungsbedingungen, Messqualität und mögliche Verzerrungen nur begrenzt nachvollziehbar. Dadurch kann nicht ausgeschlossen werden, dass bestimmte Muster im Datensatz spezifisch für diese Datenquelle sind und in anderen klinischen Populationen weniger stark auftreten. Zudem handelt es sich um einen beobachtenden Datensatz, weshalb aus den Modellvorhersagen keine kausalen Zusammenhänge abgeleitet werden können.

Auch die Modellierung selbst bietet Verbesserungspotenzial. Der Random Forest zeigt zwar die beste Gesamtleistung, weist jedoch einen niedrigeren Recall auf als einige Vergleichsmodelle. Für einen Screening-orientierten Einsatz könnte daher eine gezielte Schwellenwertoptimierung sinnvoll sein, um falsch negative Fälle zu reduzieren. Zusätzlich könnten Methoden der erklärbaren künstlichen Intelligenz, etwa SHAP-Werte, eingesetzt werden, um die Modellentscheidungen differenzierter zu interpretieren und die Nachvollziehbarkeit komplexer Modelle zu erhöhen.

Für zukünftige Arbeiten wäre es sinnvoll, größere und diversere Datensätze zu verwenden, die unterschiedliche Altersgruppen, klinische Zentren und Patientinnenpopulationen abdecken. Darüber hinaus könnten weitere Modellierungsansätze untersucht werden, beispielsweise kalibrierte Wahrscheinlichkeitsmodelle, alternative Ensemble-Verfahren oder Verfahren zur Behandlung unausgeglichener Klassen. Ebenso wäre eine prospektive Validierung relevant, um zu prüfen, ob ein solches Modell tatsächlich einen praktischen Nutzen in der medizinischen Entscheidungsunterstützung leisten kann.

8 Fazit

8.1 Zusammenfassung der zentralen Erkenntnisse und kurzer Ausblick auf potenzielle Weiterentwicklungen

In dieser Arbeit wurde untersucht, inwieweit Machine-Learning-Modelle zur Klassifikation von PCOS/PMOS auf Basis klinischer, hormoneller und sonografischer Patientinnendaten eingesetzt werden können. Der Fokus lag auf der Entwicklung, Implementierung und Evaluation verschiedener Klassifikationsmodelle. Die Analyse führte zu folgenden zentralen Erkenntnissen:

- **Eignung von Machine Learning für die PCOS-Klassifikation:** Die Ergebnisse zeigen, dass Machine-Learning-Verfahren grundsätzlich in der Lage sind, Muster im vorliegenden PCOS/PMOS-Datensatz zu erkennen. Alle betrachteten Modelle erreichten eine gute Trennfähigkeit zwischen Patientinnen mit und ohne PCOS. Dies verdeutlicht, dass klinische, hormonelle und sonografische Merkmale eine geeignete Grundlage für datenbasierte Klassifikationsansätze bilden können.
- **Bedeutung der Datenvorverarbeitung:** Die Qualität der Modellierung hing wesentlich von einer konsistenten Datenaufbereitung ab. Die Vereinheitlichung der Spaltennamen, die Entfernung technischer oder weniger relevanter Merkmale, die Behandlung potenzieller Ausreißer sowie das Feature Engineering der sonografischen Links-Rechts-Merkmale trugen dazu bei, den Datensatz in eine robuste und modellierbare Form zu überführen.

- **Modellvergleich und finale Modellauswahl:** Im Vergleich der logistischen Regression, des Entscheidungsbaums, des Random Forest und von XGBoost zeigte der Random Forest die ausgewogenste Gesamtleistung. Besonders überzeugend waren die hohe ROC-AUC, die hohe Precision und die sehr hohe Spezifität. Gleichzeitig wurde deutlich, dass der Recall im medizinischen Kontext kritisch betrachtet werden muss, da falsch negative Vorhersagen möglichst vermieden werden sollten.
- **Interpretierbarkeit der Ergebnisse:** Die Feature-Importance-Analyse zeigte, dass insbesondere sonografische Merkmale wie `Follicle_no_max` eine wichtige Rolle für die Modellentscheidung spielen. Dies ist fachlich plausibel, darf jedoch nicht kausal interpretiert werden. Die Modelle zeigen, welche Merkmale für die Vorhersage im Datensatz relevant waren, nicht aber, welche Faktoren die Erkrankung verursachen.
- **Praktische Einordnung:** Die entwickelten Modelle können keine ärztliche Diagnose ersetzen. Sie zeigen jedoch, wie Machine Learning als ergänzende Entscheidungsunterstützung eingesetzt werden könnte, beispielsweise zur strukturierten Risikoabschätzung oder zur Priorisierung weiterer diagnostischer Untersuchungen. Für einen praktischen Einsatz wären jedoch zusätzliche Validierungsschritte erforderlich.

Ausblick auf potenzielle Weiterentwicklungen: Auf Grundlage der Ergebnisse ergeben sich mehrere Ansatzpunkte für zukünftige Arbeiten:

- **Externe Validierung:** Die Modelle sollten auf unabhängigen Datensätzen aus anderen klinischen Quellen getestet werden, um ihre Generalisierbarkeit zu prüfen. Dies ist besonders wichtig, da der verwendete Kaggle-Datensatz mit 541 Beobachtungen vergleichsweise klein ist.
- **Schwellenwertoptimierung:** Für einen möglichen Screening-Kontext könnte der Klassifikationsschwellenwert angepasst werden, um den Recall zu erhöhen und weniger tatsächlich betroffene Patientinnen zu übersehen. Dabei müsste jedoch der Anstieg falsch positiver Vorhersagen berücksichtigt werden.
- **Erklärbare künstliche Intelligenz:** Zukünftige Arbeiten könnten Methoden wie SHAP oder LIME einsetzen, um die Entscheidungen komplexerer Modelle transparenter zu machen. Dies wäre insbesondere im medizinischen Kontext wichtig, da nachvollziehbare Modellentscheidungen eine Voraussetzung für Vertrauen und praktische Anwendbarkeit sind.
- **Erweiterung der Datenbasis:** Eine größere und diversere Datenbasis könnte dazu beitragen, robustere Modelle zu entwickeln. Sinnvoll wären Datensätze mit unterschiedlichen Altersgruppen, klinischen Zentren, Erhebungsmethoden und zusätzlichen medizinischen Parametern.
- **Integration in klinische Entscheidungsprozesse:** Langfristig könnten solche Modelle in Entscheidungsunterstützungssysteme eingebettet werden. Voraussetzung dafür sind jedoch medizinische Validierung, transparente Fehlerrisikoanalyse und eine klare Abgrenzung zwischen algorithmischer Empfehlung und ärztlicher Diagnose.

Zusammenfassend zeigt diese Arbeit, dass Machine Learning ein vielversprechendes Werkzeug zur Analyse klinischer PCOS/PMOS-Daten darstellt. Der Random Forest erwies sich im Rahmen der Untersuchung als stärkstes Modell, während XGBoost und logistische Regression wertvolle Vergleichsperspektiven lieferten. Die Ergebnisse sind jedoch als methodische Untersuchung und nicht als klinisch einsatzfähiges Diagnosesystem zu verstehen. Mit größeren Datensätzen, externer Validierung und besserer Erklärbarkeit könnten solche Ansätze zukünftig einen Beitrag zur datenbasierten Unterstützung medizinischer Entscheidungsprozesse leisten.

Literatur

Bobby, Prasad (2021). *PCOS Data: Polycystic Ovary Syndrome Sample Dataset based on Machine Learning Algorithm*. https://www.kaggle.com/datasets/prasadbobby/pcosdata.

International Evidence-based Guideline for PMOS (2026). *Terminology Update: Polycystic Ovary Syndrome (PCOS) renamed Polyendocrine Metabolic Ovarian Syndrome (PMOS)*. Update to the International Evidence-based Guideline.

James, Gareth u. a. (2023). *An Introduction to Statistical Learning: with Applications in Python*. 2. Aufl. Springer. DOI: 10.1007/978-3-031-38747-0.

Murphy, Kevin P. (2022). *Probabilistic Machine Learning: An Introduction*. MIT Press. ISBN: 9780262046824.

Teede, Helena J. u. a. (2026). „Polyendocrine metabolic ovarian syndrome, the new name for polycystic ovary syndrome: a multistep global consensus process“. In: *The Lancet*. DOI: 10.1016/S0140-6736(26)00717-8.

XGBoost Developers (2026). *XGBoost Documentation*. https://xgboost.readthedocs.io/en/stable/. Accessed: 2026-07-11.